

GM5 - 2025/2026

PROJET DE FIN D'ETUDES: Fitting par des méthodes de mélanges et application à la biologie

Faouzi EL KAHLA

Sous la supervision de : Giacomo NARDI

Table des matières

1 Tests de normalité **3**
1.1 Test de Shapiro-Wilk 3
1.2 Test de Lilliefors 4
1.3 Comparaison et choix entre les deux tests 8

2 Modèles de mélange et algorithme d'Espérance Maximisation **11**
2.1 Cadre d'application de l'algorithme EM 11
2.2 Principe général de l'algorithme Espérance Maximisation 13
2.3 Étape E : estimation probabiliste des variables d'appartenance 13
2.4 Etape M : maximisation de la log-vraisemblance selon le type de modèle . . . 14
2.5 Hypothèses et limites de l'algorithme EM 16

3 Etude de validation de l'algorithme EM : test d'efficacité et de robustesse **19**
3.1 Démarche de l'étude 19
3.2 Mise en évidence du biais de mauvaise modélisation 19
3.3 Impact de la taille de l'échantillon sur la qualité de l'EM 22

4 Application biostatistique de l'EM : temps d'endocytose **24**
4.1 Contexte de l'application 24
4.2 Première application de l'EM sur les données d'études 24
4.3 Deuxième application de l'EM : λ et p_0 fixé 26

5 Conclusion **28**

Introduction

Dans de nombreuses analyses statistiques, on suppose que les données proviennent d'une population homogène décrite par une distribution simple, souvent une loi normale. Cette hypothèse permet d'utiliser des outils d'inférence et de modélisation (tests Student ou Fischer, interprétations des coefficients d'une régression par exemple). Cependant, dans la pratique, il est fréquent que les données soient composées de plusieurs groupes suivant des distributions distinctes, appelés sous-populations, qui ne sont pas explicitement observables dans le jeu de données.

Une première étape logique consiste donc à étudier les distributions des données, à l'aide de tests de normalité, afin de vérifier si une modélisation par gaussienne est raisonnable dans un contexte d'étude. Dans le cas échéant, les résultats de ces tests peuvent indiquer la présence de plusieurs sous-groupes. Dans ce cas, modéliser l'ensemble des données par une seule loi de distribution est inadapté, et il est nécessaire d'utiliser des modèles pouvant représenter cette distribution plus spécifique des données.

Les modèles de mélanges représentent une réponse directe à ce problème. Ils décrivent la distribution globale des données comme une combinaison de plusieurs distributions, à définir ensuite pour constituer le modèle le plus fiable possible. Chaque composante représente alors une sous-population suivant une distribution identifiable avec ses propres paramètres, et les proportions de mélange décrivent la part de chaque sous-population dans l'ensemble des données.

Nous avons dès lors besoin de séparer notre dataset en sous-populations viables ainsi que d'estimer les paramètres définissant les sous-distributions de notre jeu de données. L'algorithme d'Espérance-Maximisation (EM) permet de traiter ce problème en alternant deux étapes : une étape d'espérance, qui calcule pour chaque observation la probabilité d'appartenir à chaque groupe, et une étape de maximisation, qui met à jour les paramètres du modèle à partir de ces probabilités. On répète ensuite ces deux étapes jusqu'à convergence de l'algorithme.

L'objectif de ce projet est d'étudier le fonctionnement de l'algorithme EM dans le cadre des modèles de mélanges, dans des cas de datasets divers. Afin de pouvoir vérifier clairement son efficacité et ses limites, l'algorithme sera appliqué à des jeux de données simulés selon des mélanges précis, dans lesquels la structure des sous-populations et leurs paramètres sont connus.

Enfin, nous réaliserons une application réelle de l'algorithme EM dans le cadre de l'étude biostatistique "Combining Global Tracking With Statistical Classification To Analyze Endocytosis Dynamics Using TIRF Microscopy", menée par mon professeur référent M. Nardi afin de découvrir les conclusions et interprétations auxquelles peuvent mener une application de l'EM dans de vraies conditions.

1 Tests de normalité

Avant d'envisager une modélisation fondée sur des distributions normales, il est nécessaire d'évaluer si les données observées sont compatibles avec cette hypothèse au risque de biaiser l'étude.

Il existe plusieurs tests statistiques permettant de comparer la distribution d'un échantillon de données à la distribution théorique de la loi normale. Ces différents tests possèdent une sensibilité différente à la manière dont l'échantillon "s'éloignerait" de la distribution normale (asymétrie, queues etc..). Il est donc nécessaire d'en manipuler plusieurs afin de s'assurer du résultat de ceux-ci et de la conclusion à tirer de ces derniers.

Dans cette partie, nous allons développer deux tests de normalités qui figurent parmi les plus utilisés : le test de Shapiro-Wilk et le test de Lilliefors (cas particulier du test de Kolmogorov, adapté à la comparaison à la loi normale).

1.1 Test de Shapiro-Wilk

Principe général :

Le test de Shapiro–Wilk consiste à dire que si les données suivent une loi normale, alors les valeurs rangées dans l'ordre croissant de l'échantillon doivent être approximativement alignées avec les quantiles théoriques d'une loi normale. Il mesure donc la corrélation entre les données triées et leurs valeurs attendues dans l'hypothèse de normalité via la statistique suivante :

$$W = \frac{\left(\sum_{i=1}^{n} a_i x_i\right)^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

où :

- $\bar{x}$ est la moyenne de l'échantillon,
- x_i correspond aux observations de notre jeu d'études, rangées dans l'ordre. Les parenthèses
- les coefficients $(a_i)_{i\in\{1,..,n\}}$ sont calculés via la formule suivante :

$$a = \frac{V^{-1}m}{||V^{-1}m||}$$

  - avec $m = \mathbb{E}\left[Z_{(1)}, \ldots, Z_{(n)}\right]^\top$, $(Z_i)_{i\in\{1,..,n\}}$ une suite échantillonnée de variable aléatoires suivant la loi normale et rangées dans l'ordre croissant, et de cardinal égal
  - V^{-1} la matrice de covariance des Z_i, présente afin de réduire l'importance des composantes d'ordre a grande variance (les extrêmes) afin de se concentrer sur les différences structurelles réelles entre le jeu de données d'étude et la loi normale
  - Enfin, le terme de normalisation au dénominateur permet notamment l'interprétabilité du résultat en bornant la statistique à 1

Concrètement, la statistique est composée comme suit :

- le numérateur mesure l'alignement des données d'études avec les données théoriques de la loi normale via un produit scalaire entre les vecteurs ordonnés a et x.
- le dénominateur est la variance totale de l'échantillon, permettant en particulier l'interprétabilité de la statistique finale.

A l'issu du calcul de cette statistique, on obtient W dont les valeurs varient entre 0 et 1. Plus W est faible, plus l'échantillon de données d'études dévie de la distribution normale. A l'inverse, plus W est proche de 1, plus sa distribution se superpose à une gaussienne.

Aussi, la p-value est évaluée via simulation de la loi de W, car on ne peut pas tirer de fonction de densité pour cette statistique.

Cas d'application et efficacité

Le test de Shapiro-Wilk est particulièrement efficace afin de déterminer des différences de symétrie, de queue trop lourde, et de manière générale les différences subtiles entre la distribution d'étude et la normale. Il est le test le plus utilisé dans les cas de petits et moyens échantillons mais présente des problèmes d'hypersensibilité pour des n plus grands. Pour des grands jeux de données, on obtient presque systématiquement un rejet de l'hypothèse nulle de normalité à cause d'une p-value systématiquement très basse. Il est donc nécessaire d'également étudier la valeur brut de la statistique W ainsi que des histogrammes et Q-Q plots afin d'appréhender correctement la distribution des données d'études, et non seulement le résultat du test.

1.2 Test de Lilliefors

Le test de Lilliefors est une variante du test de Kolmogorov-Smirnov, qui n'est pas spécifiquement un test de normalité.

Principe général :

Initialement, le test de Kolmogorov–Smirnov compare la fonction de répartition empirique d'un échantillon d'étude à une fonction de répartition théorique quelconque. Il mesure la plus grande distance verticale entre ces deux fonctions via la statistique suivante :

$$D = \sup_x |F_n(x) - F(x)|$$

Avec :

- $F_n(x)$ la fonction de répartition empirique, définie par $F_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbf{1}_{X_i \leq x}$
- $F(x)$ la fonction de répartition de la loi normale théorique.

Concrètement, cette statistique correspond au maximum de l'écart absolu entre la fonction de répartition empirique de notre échantillon et celle de la distribution choisie (ici, on pose la loi normale).

Néanmoins, le test de Kolmogorov-Smirnov est basé sur une distribution dont les paramètres sont supposés connus, et donc indépendants du jeu de données d'étude. En pratique, ce n'est pas notre cas car nous comparons la distribution de nos données avec une loi normale dont les paramètres sont la moyenne et la variances de ces mêmes données, ce qui entraine un biais dans le test. Le test de Lilliefors est alors une adaptation du test de Kolmogorov-Smirnov dans lequel on adapte les p-values à l'estimation empiriques des paramètres de la distribution comparée.

Comment le test de Lilliefors "corrige" le test Kolmogorov–Smirnov ?

Comme évoqué précédemment, les paramètres de la loi normale avec laquelle on souhaite comparer notre distribution de données ne sont pas connus initialement. En pratique, on les approche via les estimateurs suivants :

$$\hat{\mu} = \bar{X}, \qquad \hat{\sigma} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2}$$

Mais alors F_0 devient $F_{\hat{\mu},\hat{\sigma}}$, donc dépend du même échantillon qui définit F_n. Intuitivement, cela signifie qu'on "ajuste" la normale aux données, ce qui réduit artificiellement l'écart entre F_n et F_0. On obtient donc que la loi D_n n'est plus celle du KS standard, et les p-values KS renvoyées par défaut deviennent biaisées (car trop "optimistes", on obtient des p-values trop grandes et donc un test pas assez sensible).

Lilliefors propose alors d'obtenir des p-values corrigées en approximant la distribution de D_n quand $(\hat{\mu}, \hat{\sigma})$ sont estimés à partir du jeu de données (comme il est souvent le cas en pratique). Avec Monte Carlo, on simule un nombre B grand d'échantillons tels que $Z^{(b)} \sim \mathcal{N}(0,1)$ puis on recalcule $(\hat{\mu}^{(b)}, \hat{\sigma}^{(b)})$ sur chaque simulation avant de calculer $D_n^{(b)}$ afin d'obtenir un échantillon "témoin" qui va servir à comparer leur valeur à celle de D_n^{obs} tirée du test KS classique.

Enfin, la p-value est alors approximée par :

$$p = \frac{1 + \sum_{b=1}^{B} \mathbf{1}(D_n^{(b)} \geq D_n^{obs})}{B + 1}$$

La p-value calculée ici est la proportion des $D_n^{(b)}$ supérieures à notre D_n^{obs} initiale. On ajoute également 1 au total du calcul de proportion afin d'éviter que p = 0.

Comparaison des tests KS et Lilliefors

Comme vu précédemment, la différence entre les deux tests se trouve dans l'estimation de la p-value, qui est biaisée dans le cas du test KS et corrigée dans le test de Lilliefors. Pour illustrer la "naïveté" du test KS, on simule plusieurs distributions suivant une loi normale, une loi de Student et une loi de Weibull. Sur ces données, nous exécutons les deux tests et comparons le taux de rejet moyen (proportion de cas où la p-value permet de rejetter l'hypothèse de normalité de la distribution à 5%, donc $p \leq 0.05$) de ces deux tests, on obtient les valeurs suivantes :

scenario	test	taux_rejet_moy
Normale	KS_naif	0.000
Normale	Lilliefors	0.049
Student t	KS_naif	0.051
Student t	Lilliefors	0.438
Weibull	KS_naif	0.400
Weibull	Lilliefors	0.829

FIGURE 1.1 – Taux de rejet moyen de l'hypothèse de normalité (KS vs Lilliefors)

On observe déjà avec de l'échantillonnage sur loi normale que KS rejette moins l'hypothèse de normalité que le test de Lilliefors. De même, on constate que pour une loi qui ne suit pas fidèlement la loi normale (Student, Weibull), le test KS est très indulgent et rejette presque 5 fois moins de distributions que le test de Lilliefors. Enfin, on peut tracer le graphique des taux de rejet en fonction de la taille de l'échantillon initial, afin de montrer la capacité captation de non-normalité en fonction de la taille n de nos deux tests :

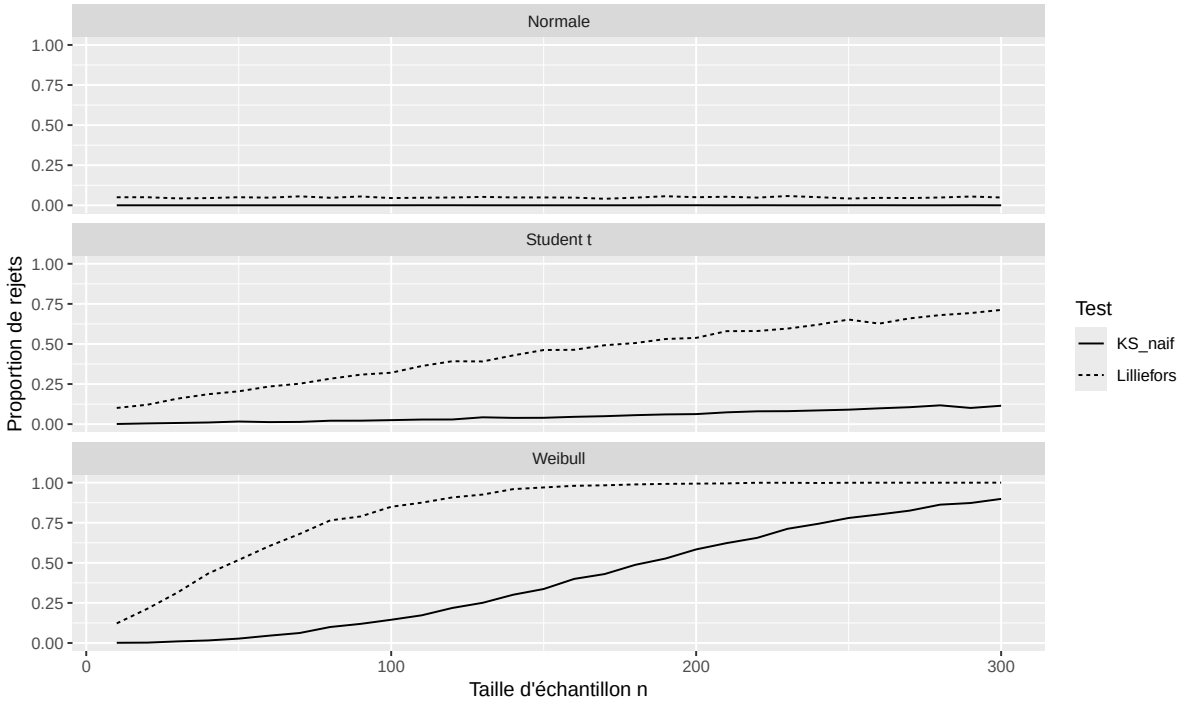


FIGURE 1.2 – Taux de rejet en fonction de la taille d'échantillon (KS vs Lilliefors)

Le test de Lilliefors rejette légèrement plus de distributions générées via la loi normale indépendemment de n. En revanche, pour les cas où la distribution n'est pas normale, on constate que le test de Lilliefors détecte la non-normalité bien plus efficacement, en particulier pour les petits échantillons. Par exemple, dans le cas des échantillons Weibull, on obtient 50% de taux de rejet de l'hypothèse de normalité pour le test de Lilliefors à n=50, taux qui n'est atteint par le test KS "naïf" qu'à n=160 environ. Le test de Lilliefors reconnait donc bien plus efficacement les cas d'éloignement de la loi normale.

Cas d'application et efficacité :

Le test de Lilliefors est globalement moins sensible que le test Shapiro-Wilk, et détecte par définition uniquement la différence la plus importante entre les deux fonctions de répartitions. Par conséquent, un résultat confirmant la conformité de l'échantillon à la loi normale est viable mais un résultat rejetant l'hypothèse de normalité ne reflète pas si la différence est uniquement locale (éventuellement corrigeable en pratique) dans la distribution ou si elle est diffuse dans tout l'échantillon. Il est donc nécessaire comme pour Shapiro-Wilk d'accompagner le résultat du test avec des visualisations globales des données avant de prendre des décisions de modélisation via loi normale.

1.3 Comparaison et choix entre les deux tests

Pour comparer l'efficacité des deux tests développés dans les parties précédentes, nous mettons en place un script dans lequel nous générons 3 types de distributions différentes :

- Un mélange gaussien à 2 composantes, même variance, moyennes séparées d'un paramètre noté delta (appelé bimodal)
- Une distribution de Weibull pour les cas d'asymétries
- Une distribution de Student pour illustrer les cas à queues lourdes

On souhaite générer des échantillons pour plusieurs tailles n et on exécute Shapiro-Wilk et Lilliefors sur tous ces échantillons, avant de comparer leur taux de rejet.

scenario	test	taux_rejet
A: mélange bimodal	Lilliefors	0.715
B: Weibull (asymétrie)	Lilliefors	0.828
C: Student (queues lourdes)	Lilliefors	0.731
H0: Normal N(0,1)	Lilliefors	0.049
A: mélange bimodal	Shapiro−Wilk	0.757
B: Weibull (asymétrie)	Shapiro−Wilk	0.910
C: Student (queues lourdes)	Shapiro−Wilk	0.835
H0: Normal N(0,1)	Shapiro−Wilk	0.051

FIGURE 1.3 – Tableau des taux de rejet moyen de la normalité (Shapiro-Wilk vs Lilliefors)

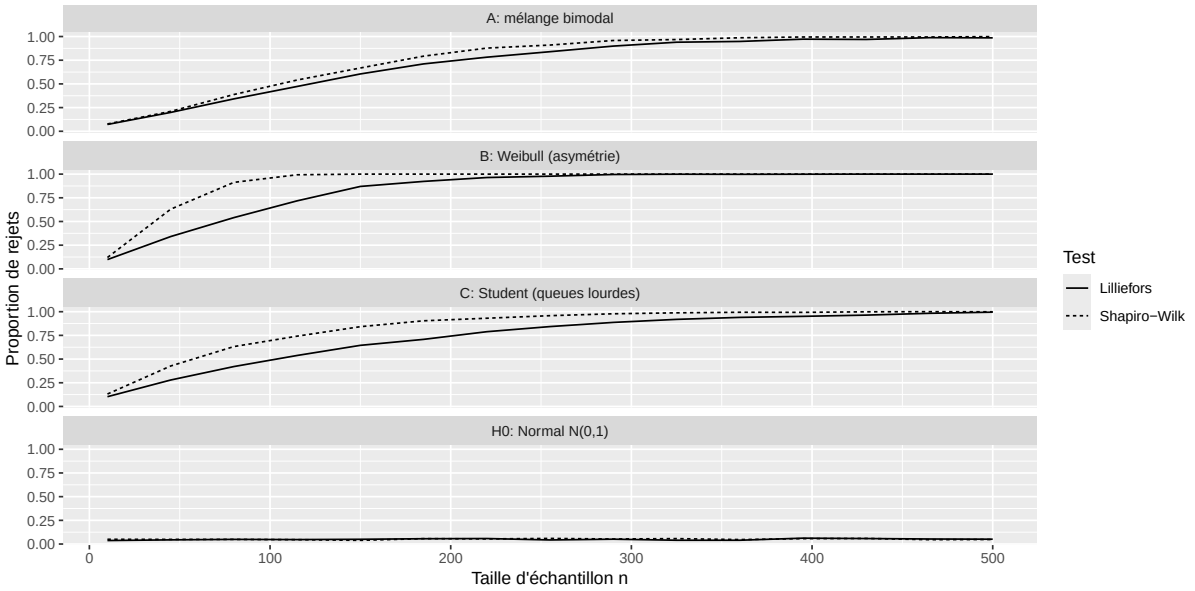


FIGURE 1.4 – Taux de rejet en fonction de la taille d'échantillon (Shapiro vs Lilliefors)

On lit sur ce tableau que comme énoncé précédemment, le test de Shapiro-Wilk est toujours plus puissant en moyenne que le test de Lilliefors, les différences de taux de rejet varient entre 4% pour le mélange bimodal (plus subtil) et 10% pour la distribution de Student, toujours en faveur de Shapiro-Wilk. Le graphe nous donne l'information que le test de Shapiro-Wilk fonctionne également davantage sur les échantillons de plus petite taille (jusqu'à 30% de différence de taux de rejet pour le cas 2 à n=50). Aussi, on constate le taux de rejet est supérieur à 95% (seuil à partir duquel on peut considérer le test comme "fiable") pour des échantillons plus petits dans le cas du test de Shapiro-Wilk (exemple : pour la distribution de Weibull, on a 95% de taux de rejet à n=100 environ pour Shapiro Wilk tandis qu'on atteint ce taux à partir de n=225 environ pour Lilliefors).

Il est également important de noter que le taux de rejet de l'hypothèse de normalité varie grandement en fonction des paramètres de la distributions initiale, comme on peut le constater via le graphique suivant traçant les taux de rejet en variant les paramètres de génération des échantillons :

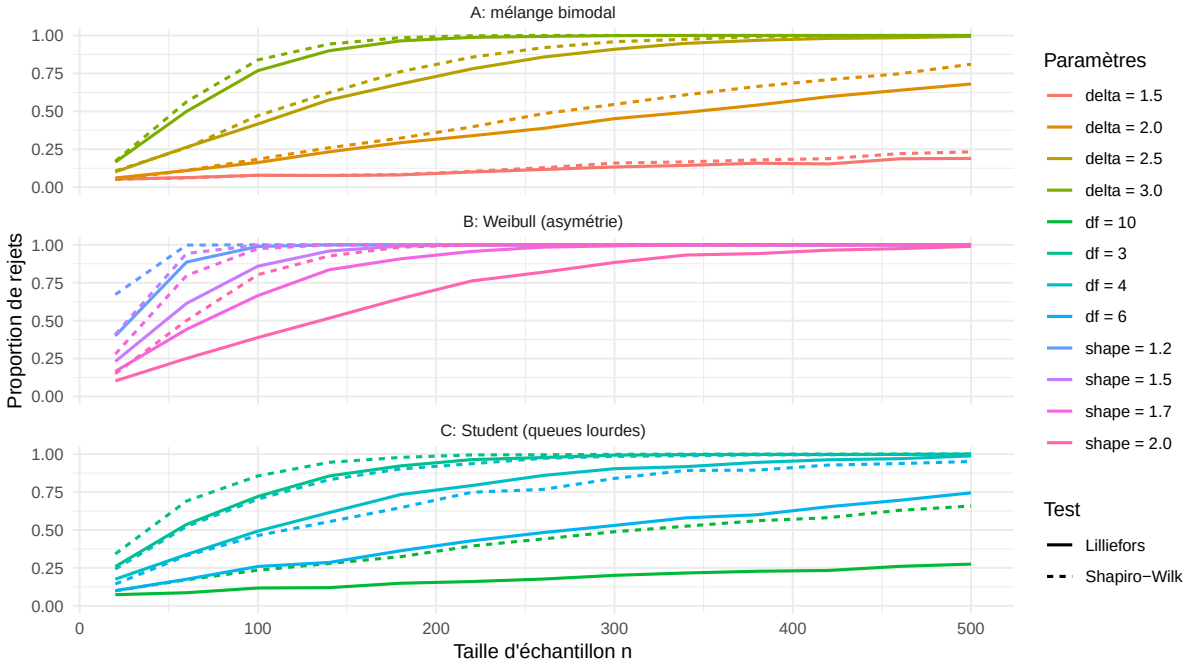


FIGURE 1.5 – Taux de rejet de la normalité selon n et variations de paramètres

On observe dans ce graphe que plus les paramètres rendent la distribution proche de la loi normale, plus l'écart de detection de non-normalité entre les tests de Shapiro-Wilk et Lilliefors s'agrandit (en faveur de Shapiro-Wilk), ce qui confirme la sensibilté plus accrue du test de Shapiro-Wilk, en particulier pour les petits échantillons ($n \leq 50$)

On en conclut qu'en pratique lorsqu'il s'agit de tester la normalité d'un échantillon, on opte d'une part pour Shapiro-Wilk si :

- on a des petits ou moyens échantillons,
- on souhaite une détection précise des déviations à la normalité,
- on veut détecter des déviations plus subtiles à la normalité (structure multi-gaussienne à moyennes proches par exemple)

D'autre part, le test de Lilliefors est pratique dans les cas suivants :

- comparaisons globales de distributions,
- pour de plus grands échantillons
- mettre en évidence la différence majeure entre deux distributions

Ce qui est important à noter, c'est qu'en pratique l'hypothèse de normalité est très souvent rejetée lorsqu'on réalise des études empiriques. Si l'on souhaite optimiser la fiabilité d'un modèle statistique, il est préférable dans ce cas d'opter pour des modèles statistiques dits "mixtes", dans lequel on sépare l'échantillon initial en sous-populations, qui elles pourront être modélisables par des distributions théoriques. Dans ce but, nous pouvons utiliser l'algorithme d'espérance maximisation (EM), dont nous allons maintenant développer le fonctionnement.

2 Modèles de mélange et algorithme d'Espérance Maximisation

Lorsqu'un jeu de données présente une distribution incompatible avec la modélisation directe, on va supposer que les observations proviennent de plusieurs sous-populations distinctes, dont les distributions sont moins hétérogènes. Dès lors, nous allons chercher à les déterminer d'une manière non biaisée via l'algorithme d'Espérance Maximisation.

Modèle de mélange :

Un modèle de mélange est un modèle probabiliste utilisé pour représenter une population hétérogène comme une combinaison pondérée de plusieurs sous-populations homogènes (suivant une loi définie). La distribution de la variable aléatoire X est modélisée comme une somme de distributions :

$$p(x \mid \Theta) = \sum_{k=1}^{K} \pi_k p_k(x \mid \theta_k),$$

où :

- K est le nombre de composantes,
- $p_k(x \mid \theta_k)$ est la densité de la k-ième composante de paramètres θ_k,
- $\pi_k \in [0, 1]$ est le poids de la composante k (concrètement la probabilité d'appartenir à la population k), avec $\sum_{k=1}^{K} \pi_k = 1$

Chaque observation est supposée provenir d'une composante inconnue à priori, ce qui permet au modèle de capter des hétérogénéités ou des sous-groupes non observés dans les données. L'estimation des paramètres est ensuite généralement réalisée par maximisation de la vraisemblance, notamment à l'aide de l'algorithme d'espérance-maximisation (EM).

2.1 Cadre d'application de l'algorithme EM

Pour commencer on pose une variable aléatoire $(Z \in 1, \ldots, K)$ représentant l'indice de la sous-population associé à une observation, avec K le nombre choisi de sous-populations. On pose également π_k décrivant la proportion d'individus d'une sous-population k dans l'échantillon global. Ainsi :

$$P(Z = k) = \pi_k, \quad \pi_k \geq 0, \quad \sum_{k=1}^{K} \pi_k = 1$$

On déduit donc que conditionnellement à Z, l'observation x suit une loi de densité f_k de paramètres contenus dans θ_k. On peut noter la densité conditionnelle comme suit :

$$p(x \mid Z = k) = f_k(x \mid \theta_k)$$

Dans ce contexte général, la fonction densité marginale de x dans un mélange de modèle suit la formule suivante :

$$p(x) = \sum_{k=1}^{K} \pi_k f_k(x \mid \theta_k)$$

Vraisemblance du modèle

On possède donc un échantillon de n observations indépendantes $(X = x_1, \ldots, x_n)$. La vraisemblance du modèle s'écrit :

$$\mathcal{L}(\Theta) = p(X \mid \Theta) = \prod_{i=1}^{n} \sum_{k=1}^{K} \pi_k f_k(x_i \mid \theta_k)$$

en notant Θ tel que $\Theta = \pi_1, \ldots, \pi_K, ; \theta_1, \ldots, \theta_K$

On obtient donc ensuite la log-vraisemblance suivante :

$$\ell(\Theta) = \sum_{i=1}^{n} \log \left(\sum_{k=1}^{K} \pi_k f_k(x_i \mid \theta_k) \right)$$

On rencontre ici le problème à résoudre dans l'algorithme EM. En effet, on a dans la formule de la log-vraisemblance une somme à l'intérieur d'un logarithme qui n'est pas simplifiable. Ainsi, on ne peut analytiquement maximiser efficacement la log-vraisemblance, ce qui nous permettrait d'aboutir à un modèle viable.

On utilise alors la variable aléatoire Z afin de définir la variable indicatrice z telle que $z_{ik} = \mathbb{1}_{Z_i = k}$. De cette manière, on peut définir la vraisemblance avec la formule suivante :

$$\mathcal{L}(\Theta, Z) = \prod_{i=1}^{n} \prod_{k=1}^{K} \left[\pi_k f_k(x_i \mid \theta_k) \right]^{z_{ik}}$$

Via la transformation de la somme en produit à l'interieur de la formule de vraisemblance, on obtient la formule suivante pour la log-vraisemblance :

$$\ell(\Theta, Z) = \sum_{i=1}^{n} \sum_{k=1}^{K} z_{ik} \left(\log \pi_k + \log f_k(x_i \mid \theta_k) \right)$$

On obtient une formule linéaire, mais cette dernière repose sur l'hypothèse d'une observation au préalable d'à quelle sous-population appartient chacune des observations x_i, on met donc en place un algorithme itératif en 2 étapes pour palier à ce problème.

2.2 Principe général de l'algorithme Espérance Maximisation

Comme développé ci-dessus, on a une formule de log-vraisemblance qui se repose sur l'observation préalable de la variable Z. L'idée de l'algorithme EM est donc de décomposer le calcul en 2 étapes distinctes :

- une étape d'estimation de la probabilité d'appartenance d'une observation à une sous-population donnée
- une étape de maximisation de la log-vraisemblance via algorithme d'optimisation classique ou résolution de système linéaire, en supposant l'appartenance aux sous-population comme donnée connue

Cette alternance de deux étapes permet la convergence vers le maximum de vraisemblance, et donc la constitution complète de notre modèle via l'appartenance des observations aux différentes sous-populations ainsi que via l'estimation des paramètres associés aux distributions de ces sous-populations.

2.3 Étape E : estimation probabiliste des variables d'appartenance

On suppose que les paramètres $\Theta^{(t)}$ sont fixés à l'itération t. L'objectif de l'étape E est d'évaluer une valeur intermédiaire pour les variables latentes d'appartenance aux sous-populations.

Concrètement, on calcule la loi suivante :

$$p(Z \mid X, \theta^{(t)}),$$

c'est-à-dire la probabilité que chaque observation appartienne à chacune des composantes du modèle.

Dans le cas d'un modèle à variables indicatrices $(z_{ik})_{i\in\{1..n\},k\in\{1..K\}}$, on calcule :

$$\gamma_{ik}^{(t+1)} = \mathbb{P}(z_{ik} = 1 \mid x_i, \Theta^{(t)}),$$

qui représente la probabilité que l'observation x_i provienne de la composante k. Elles fournissent une affectation probabiliste des données aux sous-populations.

Ils se calculent directement par la formule de Bayes :

$$\gamma_{ik}^{(t+1)} = \frac{\pi_k^{(t)} p(x_i \mid \theta_k^{(t)})}{\sum_{j=1}^{K} \pi_j^{(t)} p(x_i \mid \theta_j^{(t)})}.$$

Une fois ces probabilités obtenues, on remplace les indicatrices inconnues z_{ik} par leurs valeurs moyennes $\gamma_{ik}^{(t)}$ dans la log-vraisemblance complétée. On obtient ainsi une version exploitable de la log-vraisemblance à optimiser.

2.4 Etape M : maximisation de la log-vraisemblance selon le type de modèle

L'étape M consiste à mettre à jour les paramètres en maximisant la log-vraisemblance complétée moyenne obtenue à l'étape E :

$$\Theta^{(t+1)} = \arg\max_{\Theta} \ell(\Theta^{(t)}),$$

où $\ell(\Theta)$ est la log-vraisemblance dans laquelle les indicatrices ont été remplacées par leurs probabilités $\gamma_{ik}^{(t)}$ après l'étape E.

Selon la forme du modèle, cette maximisation peut être réalisée de différentes manières.

Cas 1 — Mélange multi-gaussien : solution analytique explicite par annulation de gradient

Dans le cas d'un mélange de lois normales multivariées, chaque composante est caractérisée par une moyenne μ_k, une matrice de covariance Σ_k et un poids de composante π_k.

Dans ce cadre, la maximisation admet des solutions explicites simples obtenues par calcul puis annulation du gradient. Les paramètres sont mis à jour par des calculs directs selon les formules suivantes :

$$\mu_k^{(t+1)} = \frac{\sum_{i=1}^{n} \gamma_{ik}^{(t+1)} x_i}{\sum_{i=1}^{n} \gamma_{ik}^{(t+1)}},$$

$$\Sigma_k^{(t+1)} = \frac{\sum_{i=1}^{n} \gamma_{ik}^{(t+1)} (x_i - \mu_k^{(t+1)})(x_i - \mu_k^{(t+1)})^\top}{\sum_{i=1}^{n} \gamma_{ik}^{(t+1)}},$$

$$\pi_k^{(t+1)} = \frac{1}{n} \sum_{i=1}^{n} \gamma_{ik}^{(t+1)}.$$

Ce cas illustre une situation commune et idéale dans laquelle l'algorithme EM est rapide à mettre en œuvre.

Cas 2 — Mélange de Weibull univarié : maximisation partiellement explicite et partiellement numérique

On considère un mélange de lois de Weibull :

$$p_k(x \mid \theta_k) = f_{\text{Wei}}(x \mid m_k, \lambda_k), \quad x > 0,$$

où chaque composante k est paramétrée par une forme $m_k > 0$ et une échelle $\lambda_k > 0$, ainsi qu'un poids π_k.

Après l'étape E, on dispose des responsabilités

$$\gamma_{ik}^{(t+1)} = \mathbb{P}(Z_i = k \mid x_i, \Theta^{(t)}).$$

La M-étape maximise la log-vraisemblance pondérée

$$\ell_k(\theta_k) = \sum_{i=1}^{n} \gamma_{ik}^{(t+1)} \left[\log m_k - m_k \log \lambda_k + (m_k - 1) \log x_i - \left(\frac{x_i}{\lambda_k} \right)^{m_k} \right].$$

La mise à jour des poids reste une moyenne empirique :

$$\pi_k^{(t+1)} = \frac{1}{n} \sum_{i=1}^{n} \gamma_{ik}^{(t+1)}.$$

Pour une forme m_k fixée, l'optimum en λ_k admet une expression fermée :

$$\lambda_k^{(t+1)} = \left(\frac{\sum_{i=1}^{n} \gamma_{ik}^{(t+1)} x_i^{m_k^{(t+1)}}}{\sum_{i=1}^{n} \gamma_{ik}^{(t+1)}} \right)^{1/m_k^{(t+1)}}.$$

En revanche, m_k est obtenu en résolvant numériquement l'équation (issue de $\partial \ell_k / \partial m_k = 0$) :

$$0 = \frac{1}{m_k} - \log \lambda_k + \frac{\sum_{i=1}^{n} \gamma_{ik}^{(t+1)} \log x_i}{\sum_{i=1}^{n} \gamma_{ik}^{(t+1)}} - \frac{\sum_{i=1}^{n} \gamma_{ik}^{(t+1)} \left(\frac{x_i}{\lambda_k} \right)^{m_k} \log \left(\frac{x_i}{\lambda_k} \right)}{\sum_{i=1}^{n} \gamma_{ik}^{(t+1)}}.$$

En pratique, on alterne mise à jour de λ_k pour une valeur courante de m_k, puis résolution de l'équation en m_k par Newton–Raphson (ou une méthode quasi-Newton), ce qui correspond à une M-étape numérique stable.

Cas 3 — Mélange hybride Weibull + exponentielle + gaussienne : M-étape par blocs (optimisation composante par composante)

On considère un mélange à $K = 3$ composantes de familles différentes :

$$p(x) = \pi_W f_{\text{Wei}}(x \mid m, \lambda) \; + \; \pi_E f_{\text{Exp}}(x \mid \eta) \; + \; \pi_G f_{\mathcal{N}}(x \mid \mu, \sigma^2),$$

avec $x > 0$ pour les composantes Weibull et exponentielle (dans ce cas, on suppose les données positives ou prétraitées en conséquence). Après l'étape E, on dispose des responsabilités $\gamma_{iW}, \gamma_{iE}, \gamma_{iG}$.

La M-étape se décompose par blocs car $\ell(\Theta) = \ell_W(m, \lambda) + \ell_E(\eta) + \ell_G(\mu, \sigma^2) + \ell_\pi(\pi)$: chaque composante se met à jour indépendamment via sa log-vraisemblance pondérée.

Pour les poids, on a :

$$\pi_c^{(t+1)} = \frac{1}{n}\sum_{i=1}^{n} \gamma_{ic}^{(t+1)}, \qquad c \in \{W, E, G\}.$$

Pour une exponentielle de taux $\eta > 0$, $f_{\text{Exp}}(x \mid \eta) = \eta e^{-\eta x}$, l'optimum est explicite :

$$\eta^{(t+1)} = \frac{\sum_{i=1}^{n} \gamma_{iE}^{(t+1)}}{\sum_{i=1}^{n} \gamma_{iE}^{(t+1)} x_i}.$$

Pour la composante gaussienne (univariée pour simplifier), les mises à jour sont analytiques :

$$\mu^{(t+1)} = \frac{\sum_{i=1}^{n} \gamma_{iG}^{(t+1)} x_i}{\sum_{i=1}^{n} \gamma_{iG}^{(t+1)}}, \qquad (\sigma^2)^{(t+1)} = \frac{\sum_{i=1}^{n} \gamma_{iG}^{(t+1)} (x_i - \mu^{(t+1)})^2}{\sum_{i=1}^{n} \gamma_{iG}^{(t+1)}}.$$

Pour la composante Weibull, même logique que le cas 2 :

$$\lambda^{(t+1)} = \left(\frac{\sum_{i=1}^{n} \gamma_{iW}^{(t+1)} x_i^{m^{(t+1)}}}{\sum_{i=1}^{n} \gamma_{iW}^{(t+1)}} \right)^{1/m^{(t+1)}},$$

et $m^{(t+1)}$ est obtenu par résolution numérique de l'équation $\partial \ell_W / \partial m = 0$.

2.5 Hypothèses et limites de l'algorithme EM

L'algorithme d'espérance–maximisation repose sur plusieurs hypothèses implicites et présente des limites pratiques qui doivent être prises en compte lors de son utilisation, tant du point de vue numérique que statistique et interprétatif.

Critère de convergence et rapidité.

À chaque itération, l'algorithme EM garantit une augmentation (ou stagnation au minimum) de la log-vraisemblance observée :

$$\ell(\Theta^{(t+1)}) \geq \ell(\Theta^{(t)}).$$

La convergence est généralement évaluée à l'aide d'un critère d'arrêt basé sur :

- la variation relative de la log-vraisemblance, $|\ell^{(t+1)} - \ell^{(t)}| < \varepsilon$,
- la variation des paramètres, $\|\Theta^{(t+1)} - \Theta^{(t)}\| < \varepsilon$,
- ou un nombre maximal d'itérations.

En pratique, l'EM converge souvent rapidement dans les premières itérations, mais peut ralentir fortement à proximité d'un optimum, en particulier lorsque les composantes sont difficilement identifiables. De plus, la convergence est seulement vers un optimum local de la vraisemblance, ce qui rend l'initialisation des paramètres essentielle.

Choix du nombre de composantes K.

Le nombre de sous-populations K n'est généralement pas connu a priori et doit être estimé à partir des données. Une approche standard consiste à comparer plusieurs modèles pour différentes valeurs de K à l'aide des critères d'information pénalisés suivants :

$$\text{AIC} = -2\ell(\hat{\Theta}) + 2p, \qquad \text{BIC} = -2\ell(\hat{\Theta}) + p \log n,$$

où p est le nombre de paramètres du modèle et n la taille de l'échantillon. Ces critères réalisent un compromis entre qualité d'ajustement (log-vraisemblance) et complexité du modèle (pénalisation). En pratique, on sélectionne la valeur de K minimisant l'AIC ou le BIC.

Le choix de K a un impact direct sur l'interprétabilité du modèle : un nombre trop faible de composantes peut ne pas expliciter certaines structures hétérogènes, tandis qu'un nombre trop élevé peut conduire à des composantes artificielles, difficilement interprétables et sensibles au bruit.

Limites des critères AIC/BIC et implications interprétatives.

Bien que largement utilisés, les critères AIC et BIC présentent plusieurs limites dans le cadre des modèles de mélange. L'AIC tend à favoriser des modèles plus complexes (sur-ajustement), et le BIC pénalise plus fortement la complexité et peut sous-estimer le nombre réel de composantes lorsque les sous-populations sont proches. Aussi, les critères sont purement statistiques et ne garantissent pas une interprétation au sens pratique pertinente des composantes dans le cas d'une étude concrète.

Pour illustrer ces limites, on génère un échantillon multigaussien (pour K=3), puis on exécute l'algorithme EM une fois pour chaque K de 1 à 6 afin de comparer à posteriori les qualités des modèles ajustés via :

- l'AIC
- le BIC
- l'ARI (adjustment rand index), qui compare les couples d'observations qui appartiennent à la même sous-population initialement et via l'EM (a) et les couples qui appartiennent à des sous-populations différentes dans les deux cas (b) via la formule : $\frac{a+b}{\binom{n}{2}}$
- la distance en norme L^2 des densités obtenues

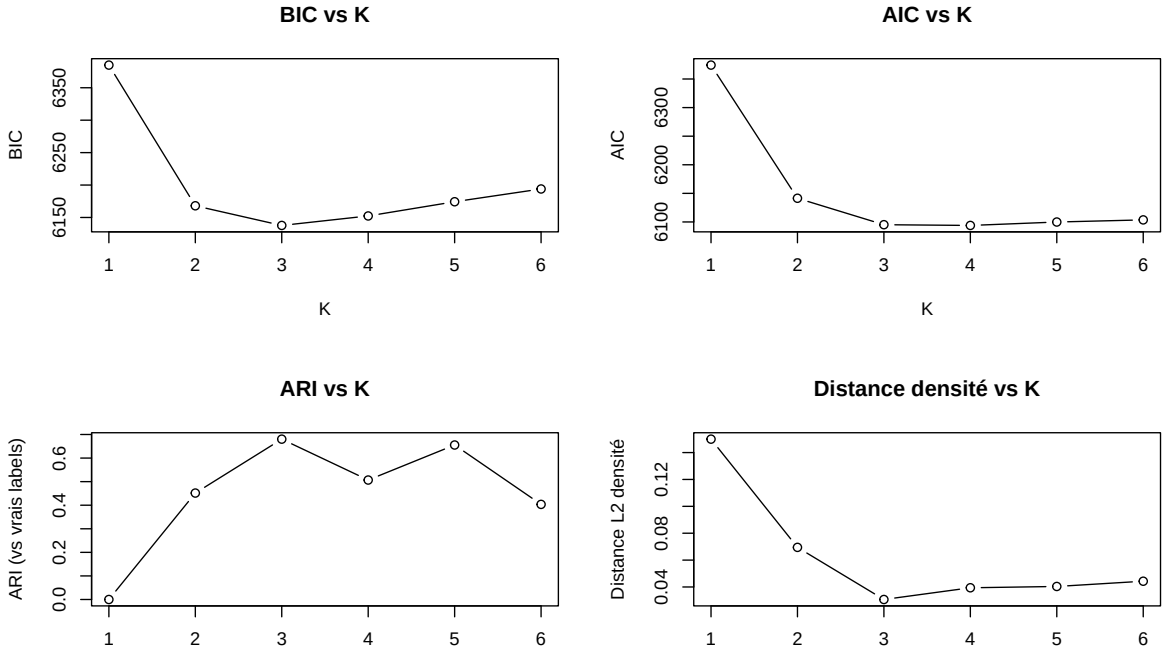


FIGURE 2.1 – Valeurs des critères de sélection en fonction de K

On observe bel et bien que tous les critères sont favorables à K=3 dans le cas de notre échantillon multigaussien. En revanche, on peut observer que l'AIC est effectivement plus enclin à favoriser des modèles à grands K par rapport au BIC, l'ARI montre qu'un ajustement à 5 composantes est relativment fidèle au partitionnement des données initiales (mais peut être plus complexe à interpréter d'un point de vue concret, les données provenant "en réalité" d'uniquement 3 sous-populations).

Méthodes d'initialisation des paramètres.

Comme évoqué brièvement précédemment, la performance de l'algorithme EM dépend beaucoup de l'initialisation des paramètres $\Theta^{(0)}$, car la non-convexité de la log-vraisemblance des modèles de mélange peut mener à des convergences lentes, à des solutions aberrantes ou à un optimum local peu pertinent. Plusieurs stratégies d'initialisation sont utilisées en pratique.

La méthode la plus simple consiste à initialiser aléatoirement les paramètres du modèle, par exemple en tirant les poids $(\pi_k)_{k\in\{1..K\}}$ de manière uniforme, et les autres paramètres à partir de valeurs empiriques tirées des données. Cette approche est plus facile à implémenter mais présente une forte variabilité des résultats.

Une approche plus stable est l'initialisation basée sur un algorithme de partitionnement, notamment le k-means. Les centres des clusters obtenus servent alors d'estimation initiale des paramètres de localisation (comme la moyenne dans le cas gaussien).

Enfin, il est également très commun de combiner ces stratégies avec une approche multi-démarrages : on exécute l'algorithme EM plusieurs fois à partir d'initialisations différentes, et la solution retenue est celle associée à la plus grande log-vraisemblance finale.

3 Etude de validation de l'algorithme EM : test d'efficacité et de robustesse

3.1 Démarche de l'étude

Afin d'évaluer les performances de l'algorithme d'espérance–maximisation (EM), nous mettons en place une étude de simulation fondée sur l'évaluation de deux aspects "limitants" de l'algorithme EM. Pour chaque distribution que nous traiterons, des échantillons seront générés à partir de paramètres connus, ce qui permet de disposer d'un modèle de référence et d'un accès direct aux vrais paramètres.

Tout d'abord, pour un échantillon donné, plusieurs valeurs candidates du nombre de composantes K sont considérées. Pour chaque valeur de K, l'algorithme EM est exécuté jusqu'à convergence puis les modèles obtenus sont comparés à l'aide de critères pénalisés (AIC, BIC). Cette étape vise à évaluer la capacité de l'EM à identifier un nombre de sous-populations cohérent avec la structure réelle des données.

Dans un second temps, l'échantillon simulé à partir d'un mélange donné est ajusté non seulement avec le modèle correct, mais également avec un modèle alternatif. Cette approche permet d'analyser la sensibilité de l'algorithme EM aux hypothèses de modélisation (qui peuvent être imprécises), et d'évaluer la robustesse des estimations de paramètres et des affectations de classes en cas non optimal .

Enfin, nous ferons également varier la taille de l'échantillon d'étude afin de constater la qualité du fitting des composantes et des paramètres dans des cas où les données sont peu nombreuses.

3.2 Mise en évidence du biais de mauvaise modélisation

Une des caractéristiques limitantes de l'algorithme EM est la nécessité pré-fitting de la spécification des distributions que suivent les composantes du mélange. Par conséquent, un "mauvais pari" sur les composantes du modèle de mélange peut causer un biais sur plusieurs aspects de la modélisation.

Afin d'illustrer cela, nous mettons en place une distribution composée de 2 sous-populations (K=2), une Weibull et une exponentielle, puis nous exécutons l'algorithme EM en supposant un modèle multi-gaussien. Nous évaluerons ensuite le nombre de composantes optimal via critère de sélection AIC et BIC, ainsi que la qualité du modèle via la distance en norme L2 entre la densité initiale et celle obtenue via fitting. Après exécution de l'EM, on obtient le graphe de comparaison suivant :

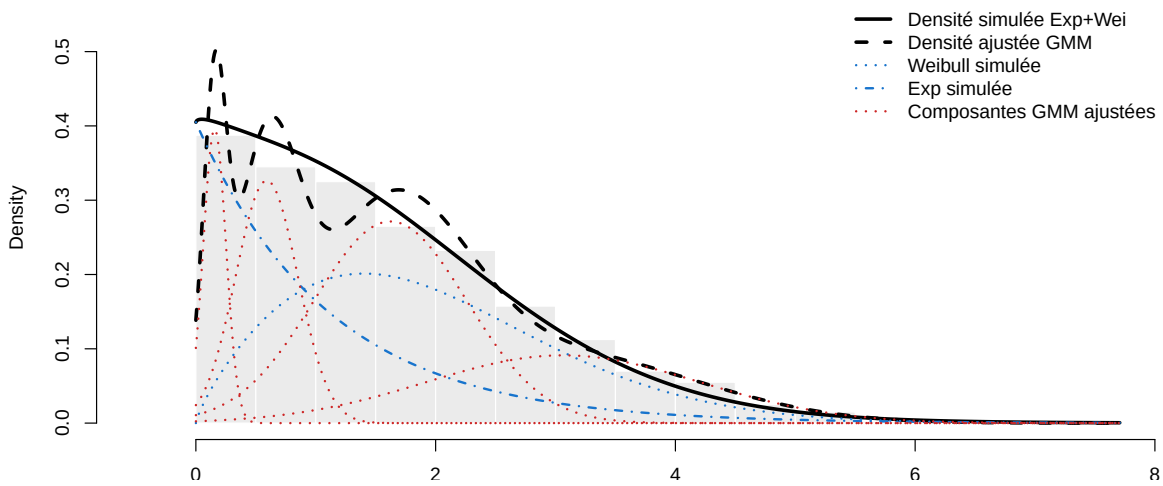


FIGURE 3.1 – Densité simulée vs ajustée : Weibull+Exp vs GMM (K=4)

La courbe pleine représente le mélange entre les distributions Weibull et exponentielle, celle en pointillés le meilleur modèle multigaussien via critère de sélection BIC, après exécution de l'EM. On observe d'emblée que la mauvaise spécification de la loi suivie par les sous-populations ont artificiellement augmenté le nombre de composantes, on obtient un modèle optimal selon le BIC pour K=4 alors qu'on a à l'origine K=2. Cela s'explique par plusieurs aspects :

- Premièrement, les domaines de définition des densités Weibull et exponentielle sont positifs, avec un pic de densité proche de 0 pour l'exponentielle. Cela a pour conséquence une difficulté pour une gaussienne à fit correctement l'irrégularité de densité présente en 0 et on observe donc une composante gaussienne artificielle proche de 0, qui en plus de cela ne parvient pas totalement à annuler la distribution de masse pour x négatif (on a 1% de la masse totale en négatif, au lieu de 0 originellement).
- De plus, la distribution de Weibull implique dans la distribution de mélange une queue plus lourde à droite, qui ne correspond pas à celle d'une gaussienne. Pour fit correctement cette courbe avec une multi-gaussienne, le modèle ajoute donc une composante gaussienne de moyenne $\mu \approx 4$ et à grande variance afin de simuler cette queue plus lourde.

Enfin, on peut comparer ce mauvais ajustement à un fitting bien spécifié afin d'observer si l'allure globale de la densité ajustée et le nombre de composantes est mieux déterminé. Après exécution de l'EM selon le bon modèle initial :

On constate que la sélection via critère BIC a privilégié un modèle à 2 composantes, ce qui correspond au nombre réél de sous-populations contenues dans l'échantillon d'études. De plus, contrairement à l'ajustement GMM ci-dessus qui oscille beaucoup autour de la densité vraie, l'allure des densités totales est très similaire.

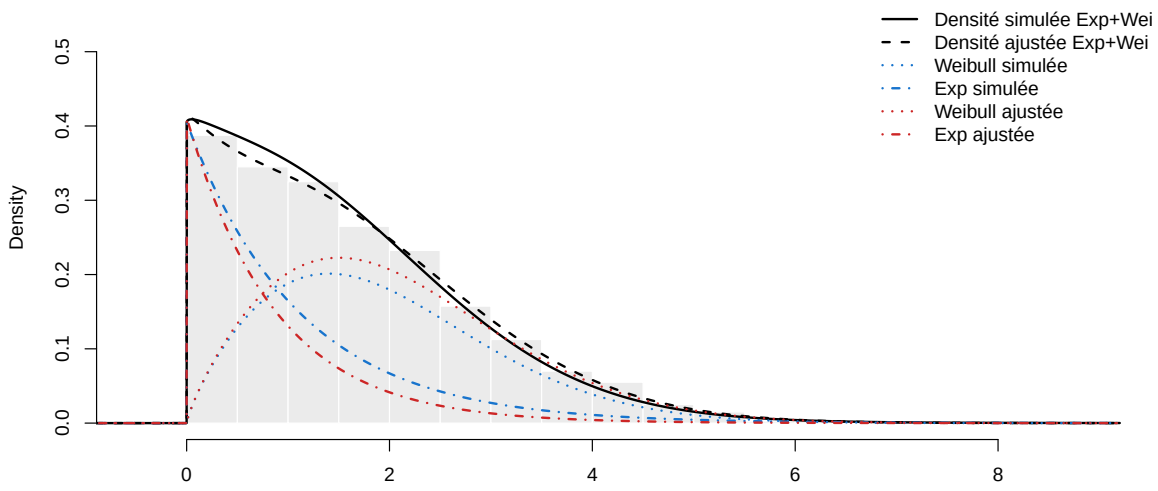


FIGURE 3.2 – Densité réelle vs ajustée : Exp+Weibull vs Exp+Weibulls

Qualité globale du modèle "mal spécifié" :

Outre le problème d'interprétabilité causé par un nombre trop grand de sous-populations estimé, il est également nécessaire d'évaluer le biais structurel induit par la mauvaise spécification des composantes. Pour évaluer la qualité du modèle, on exécute l'EM en spécifiant correctement les distributions à priori (Weibull et exponentielle), puis on compare la distance en norme $W^{1,2}$ entre f_0 et $\hat{f}_{exp,wei}$ et la distance en norme $W^{1,2}$ entre f_0 et f_{gmm}. On choisit cette métrique car la norme $W^{1,2}$, définie par la somme des normes L^2 de la fonction et de sa dérivée, permet de capter à la fois l'erreur globale et l'erreur liée à l'allure de la courbe fittée (notamment si la courbe fittée oscille autour de la densité vraie). On obtient les valeurs :

Modele	$W^{1,2}$
EM Weibull+Exp (bien spécifié)	0.136399
EM GMM (mal spécifié) (K=4)	7.824746

FIGURE 3.3 – Distances entre densité simulée et densités ajustées (en norme $W^{1,2}$)

On reporte ici que la distance en norme $W^{1,2}$ avec la densité réelle dans le cas d'un modèle mal spécifié est bien plus grande que dans le cas où il l'est correctement (et ce d'un facteur de plus de 50, non négligeable). Cela reflète clairement un fitting global moins précis, et ce malgré l'ajout de composantes artificielles dans le cas du modèle multigaussien (GMM).

On en conclut qu'une mauvaise spécification à priori des distributions des sous-populations induit à la fois des biais dans l'estimation du nombre optimal de composantes (ce qui entraîne moins d'interprétabilité pour le modèle en pratique) et un fitting global moins qualitatif.

3.3 Impact de la taille de l'échantillon sur la qualité de l'EM

Dans cette sous-partie, nous souhaitons mettre en évidence le fait qu'un échantillon d'étude plus grand mène à une estimation plus précise des paramètres des composantes après exécution de l'EM. En effet, en théorie, pour $(X_1, \ldots, X_n)$ i.i.d. de densité $f(x \mid \theta)$. La log-vraisemblance empirique est

$$\ell_n(\theta) = \sum_{i=1}^{n} \log f(X_i \mid \theta).$$

On introduit la log-vraisemblance moyenne

$$\bar{\ell}_n(\theta) = \frac{1}{n}\ell_n(\theta) = \frac{1}{n}\sum_{i=1}^{n} \log f(X_i \mid \theta).$$

Par la loi des grands nombres, pour tout (θ) fixé :

$$\bar{\ell}_n(\theta) \xrightarrow[n\to\infty]{} \mathbb{E}_{\theta_0}\big[\log f(X \mid \theta)\big],$$

où θ_0 est le vrai paramètre générateur des données.

Or, cette quantité est maximisée uniquement en $\theta = \theta_0$ si le modèle est identifiable via distributions paramétrées. Donc quand n augmente, la log-vraisemblance empirique devient une approximation de plus en plus fidèle de sa version théorique, et donc son maximum se rapproche du maximum théorique situé en θ_0.

Afin de vérifier cela en pratique, il est nécessaire de simuler plusieurs échantillons pour chaque n afin de tirer une qualité "moyenne" (via la métrique norme $W^{1,2}$) de fitting associé à la taille n. On obtient les valeurs suivantes (avec 50 échantillons simulés pour chaque valeur de n) :

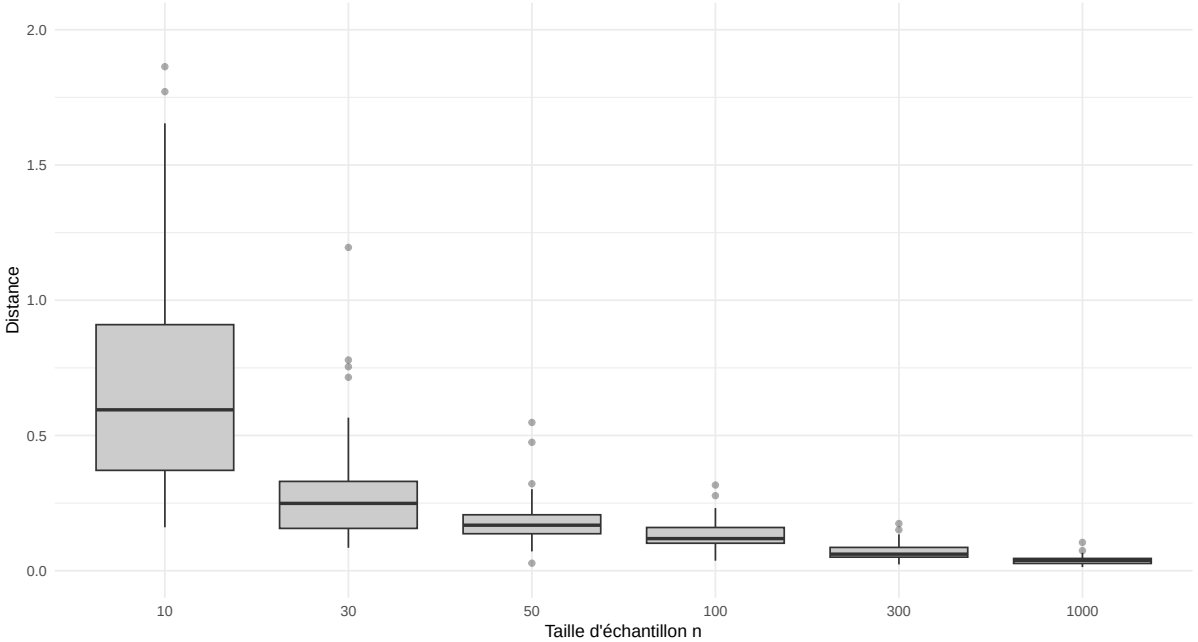


FIGURE 3.4 – Boxplot des distances entre densité simulée et densité ajustée (en fonction de n)

Ces boîtes à moustaches nous permettent de constater que la distance moyenne avec la densité réelle suivie par nos échantillons simulés est de moins en moins élevée à mesure que n augmente. On confirme donc l'hypothèse théorique soumise ci-dessus : la qualité du fitting EM dépend de la taille de n, et elle augmente avec n.

Pour conclure, en ce qui concerne la pratique, la métrique utilisée (distance en norme $W^{1,2}$) ne permet pas de définir de "seuil de confiance" à partir duquel on pourrait faire confiance à un échantillon en fonction de sa taille. En revanche, on constate que le resserrement des quantiles autour de la médiane indique que, lorsque la taille d'échantillon augmente, on peut faire davantage confiance en la qualité de l'EM.

4 Application biostatistique de l'EM : temps d'endocytose

4.1 Contexte de l'application

L'endocytose est un mécanisme par lequel une cellule fait entrer à son intérieur des éléments présents à sa surface ou dans son environnement proche. Ce processus repose sur la formation de structures à la membrane de la cellule appelées puits de clathrine, qui apparaissent puis disparaissent en un certain temps donné. Il est important de noter que certaines de ces structures aboutissent à une insertion effective dans la cellule, tandis que d'autres se désassemblent rapidement sans succès. La durée de vie de ces structures constitue donc une information essentielle pour comprendre le déroulement du processus d'endocytose. Dans l'étude de référence, les statisticiens utilisent des images de microscopie TIRF pour suivre précisément au cours du temps ces puits de clathrine et leur interaction avec différentes protéines impliquées dans l'endocytose, notamment la dynamine ou l'endophiline que nous étudierons dans cette partie.

Les temps de vie mesurés sont très diversifiés. On observe des événements très courts, correspondant à des tentatives non fonctionnelles (dites avortées), et des événements plus longs, associés à des structures fonctionnelles. Cette hétérogénéité rend inadaptée une description globale unique des données. L'algorithme EM fournit donc un cadre adapté à cette situation.

Dans l'article de référence, les auteurs modélisent les temps de vie à l'aide d'un mélange composé d'une loi exponentielle afin de capter les événements avortés (densité proche de 0), et de plusieurs lois normales, décrivant des groupes d'événements plus longs et plus stables.

Afin de ne pas simplement reproduire l'étude, nous allons retenir une autre modélisation intéressante dans ce travail : un mélange exponentielle + lois de Weibull. Ce choix est motivé notamment par le fait que les temps de vie sont strictement positifs, en plus du fait que les lois de Weibulls sont capables de capter les asymétries.

4.2 Première application de l'EM sur les données d'études

Nous avons à notre disposition les cas où les puits de clathrine sont en contact avec l'une des deux protéines suivantes : endophiline et dynamine. Nous séparons donc notre EM en 2, un cas pour la colocation avec l'endophiline (et absence de dynamine), et un deuxième pour la colocation avec la dynamine (et absence d'endophiline). De plus, nous reprenons la méthode de sélection du nombre de composantes mentionné précédemment dans ce projet, via calcul du BIC.

K	logLik	n	p	BIC	iter
6	−10612.0206394609	2260	19	21370.7805606749	131
5	−10623.9291375306	2260	16	21371.4281965375	110
4	−10670.23502349	2260	13	21440.8706081795	61
3	−10713.5002832174	2260	10	21504.2317673574	86
2	−10793.7035796198	2260	7	21641.4689998855	142
1	−10925.9892247602	2260	4	21882.8709298895	47

(a) siDyn2

K	logLik	n	p	BIC	iter
5	−21329.2901366969	4671	16	42793.7663287618	75
6	−21321.2443184142	4671	19	42803.0220775779	63
4	−21370.256130731	4671	13	42850.3509314486	65
3	−21429.3622978226	4671	10	42943.2158802502	66
2	−21550.5442481783	4671	7	43160.2323955801	33
1	−21958.2908164829	4671	4	43950.3781468078	41

(b) siEndoA2

FIGURE 4.1 – Tables BIC pour les modèles ajustés via EM

D'après le tableau de résumé de l'EM, on a un BIC qui atteint son minimum pour un modèle à 6 et 5 composantes Weibull pour les cas étudiés. Les valeurs des paramètres liés aux composantes de ces modèles sont les suivantes :

composante	poids	lambda_ou_forme	echelle
Exp	1.247807e−06	0.0256332	NA
Weibull_1	3.335414e−01	3.2310864	78.35944
Weibull_2	1.871709e−01	2.9401722	32.26479
Weibull_3	1.149191e−01	10.8450804	130.39223
Weibull_4	7.288696e−02	4.2926279	7.75618
Weibull_5	1.676777e−01	140.7356090	148.58962
Weibull_6	1.238027e−01	3.2295389	15.23266

(a) siDyn2

composante	poids	lambda_ou_forme	echelle
Exp	0.0004188377	0.02576572	NA
Weibull_1	0.2074854462	5.40558529	113.20214
Weibull_2	0.2337975429	140.48152868	148.81431
Weibull_3	0.1762266882	2.49219714	24.27882
Weibull_4	0.0554148835	3.84271168	8.48028
Weibull_5	0.3266566014	3.05742525	62.43238

(b) siEndoA2

FIGURE 4.2 – Tables de paramètres pour les modèles ajustés via EM

On observe notamment dans ces tableaux de valeurs que la composante exponentielle n'a pas beaucoup de poids dans le mélange. Afin de comprendre pourquoi, traçons les allures des densités fittées de nos sous-populations. On obtient les courbes ci-dessous :

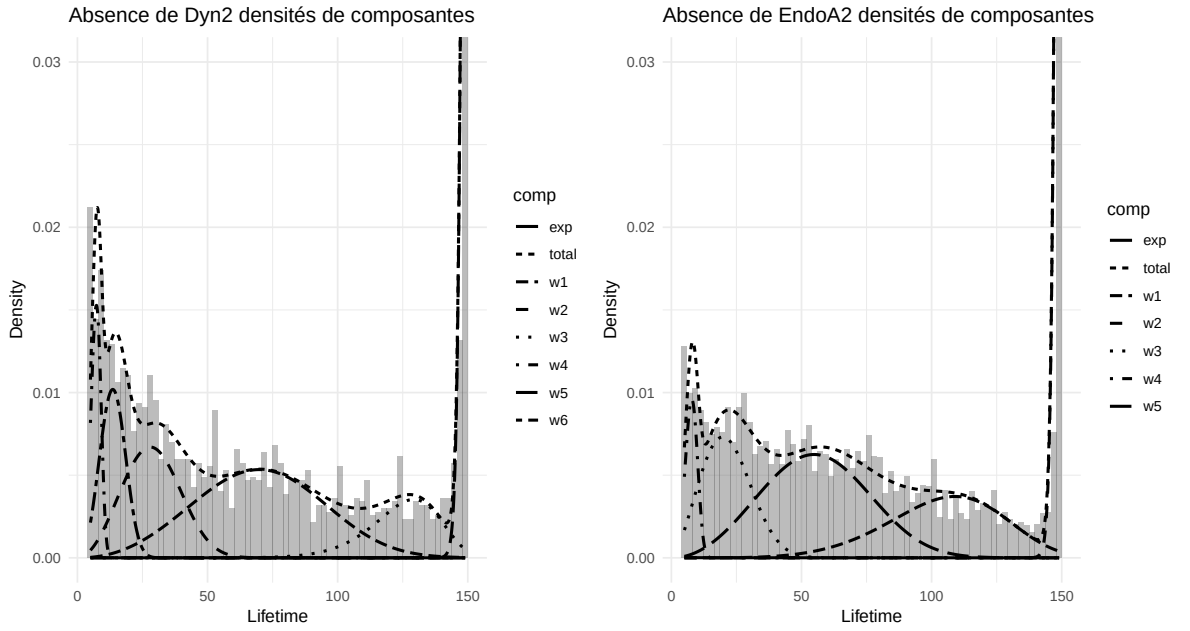


FIGURE 4.3 – Distributions des sous populations sans Dyn2 / sans EndoA2

On observe ici un imprévu : la composante exponentielle n'a pas été fittée par l'EM afin de combler les évènements d'abortions comme nous l'avions prévu. En effet, la composante exponentielle ne représente qu'une petite proportion de la densité totale (0,3%), et on constate que ce sont plusieurs des composantes Weibulls qui ont été fittées pour former un pic de densité pour les temps d'insertions faibles (les composantes 2, 4 et 6 dans le cas siDyn et les composantes 3 et 4 dans le cas siEndo).

En l'état, étant donné que l'exponentielle n'a pas de rôle significatif dans l'estimation des sous-populations par l'EM, nous pouvons interpréter ce fitting comme étant un multi-weibull simple. Pour l'interprétation, il est important de prendre en compte une information cruciale : la dynamine (Dyn2) est indispensable dans le processus d'endocytose. On peut donc considérer les sous-populations tirées du fitting sur le dataset EndoA2ClcSiDyn2_coloc ne sont pas des sous-populations de puits de clathrine productifs (ils ne permettent pas l'endocytose complète).

La comparaison entre les deux cas d'étude devient compliquée en raison d'un problème central d'interprétabilité lié au nombre élevé de composantes retenues par le BIC et à leur fort chevauchement. Dans les deux cas, le modèle optimal sélectionné comporte un nombre important de Weibull (six pour siDyn, cinq pour siEndoA2). Or, ces composantes ne correspondent pas à des groupes nettement séparés : plusieurs d'entre elles occupent des zones de temps très proches, en particulier dans les durées courtes et intermédiaires. Les courbes se superposent largement, ce qui signifie qu'une même plage de temps est expliquée simultanément par plusieurs Weibull aux paramètres proches. De plus, les populations d'un cas ne sont pas associables à des populations de l'autre, ce qui nous laisse avec des sous-populations uniques difficiles à comparer.

Dans ce contexte, les composantes ne sont pas calibrées pour représenter des sous-populations biologiques distinctes, mais plutôt une décomposition d'une forme globale de densité sans réel sens pratique et interprétatif, ce qui n'est pas notre but. Ainsi, le problème n'est pas que le modèle soit incorrect, mais qu'il devient difficile d'associer chaque composante à un "type d'observations" précis. Il faut donc dans l'idéal avoir moins de composantes à interpréter, et donc adopter des distributions plus fidèles à la distribution globale des données. Comme nous avons pu le constater, le surnombre des composantes Weibulls concentrées autour des temps courts constituent un frein à l'interprétabilité, nous allons donc contraindre l'EM à adopter une courbe exponentielle afin de tirer des interprétations biologiques cohérentes.

4.3 Deuxième application de l'EM : λ et p_0 fixé

D'après l'étude dont nous tirons notre dataset, on nous informe que les évènements avortés suivent normalement une distribution exponentielle, chose que nous ne pouvons pas coupler directement avec des Weibulls dans le cadre de l'EM. Afin de pallier ce problème, nous pouvons faire en sorte de n'optimiser que les composantes Weibull de notre mélange via l'EM, en fixant avant l'exécution de l'algorithme les paramètres λ et p_0 de la composante exponentielle. Pour cela, nous prenons comme référence la composante exponentielle fixée dans l'étude de référence, avec $\lambda \approx 0.04$ et $p_0 = 0.475$ dans les 2 cas siEndo et siDyn. On obtient alors les fittings suivant :

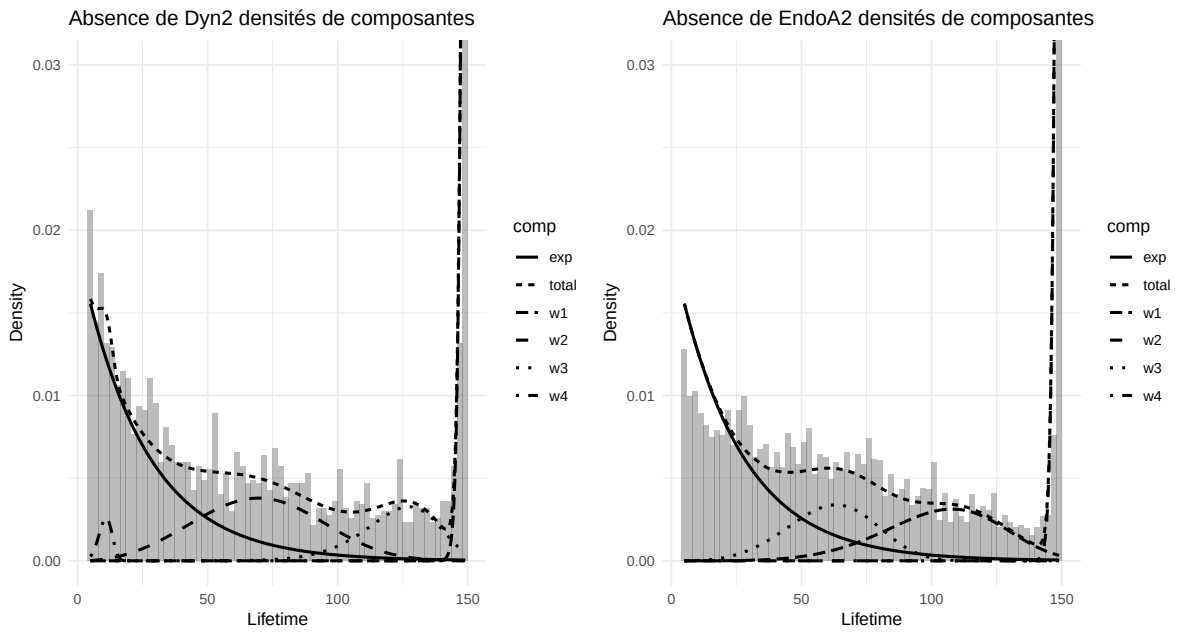


FIGURE 4.4 – Distributions des sous-populations, lambda fixé

On constate qu'avec la composante exponentielle présente dans le mélange, le modèle optimal selon le BIC est un modèle à 4 composantes Weibull. D'abord, on a la composante 4, qui est présente dans les deux fittings, mais ne représente dans les 2 cas qu'une partie infime des responsabilités dans leur modèle respectifs (moins de 1% de la densité totale pour les deux modèles). Elle est probablement un artéfact de l'exécution de l'EM, du critère de selection BIC et de la fixation des paramètres exponentiels, qui a valorisé l'augmentation de la logvraisemblance vis à vis de l'augmentation du nombre de paramètres ($BIC_{K=4}$ = 43369 et $BIC_{K=3}$ = 43376 dans le cas siDyn, les valeurs sont très proches). De plus, la composante 2, à l'instar du fitting précédent, forme un pic contenant les enregistrements très proches de 150, qui constituent les puits de clathrine "statiques", non productifs.

Cependant, la composante 1 possède une allure différente dans les deux cas. En effet, cette dernière, dans le cas siEndoA2 (cas productif), semble avoir englobé en grande partie les composantes 1 et 3 du cas siDyn (cas non-productif). Là où se trouve le point d'overlap des composantes 1 et 3 du cas siDyn on retrouve le pic de densité de la composante 1 du cas siEndo, ce qui suggère effectivement que celle-ci est un mélange des deux composantes observées dans le cas non productif.

De plus, le rassemblement des composantes non-productives dans la composante 1 du cas productif permet à la composante 3 du cas siEndoA2 de décrire la distribution des puits de clathrine actifs. Cette hypothèse est soutenue par le décalage vers des temps plus courts en moyenne pour la composante 3 (autour de 55-60, en accord avec l'étude originale quant à la durée moyenne des puits actifs) et une queue moins lourde représentant un phénomène plus défini, ce qui correspond à nos conclusions du fitting précédent ainsi qu'aux conclusions de l'étude de référence.

5 Conclusion

Dans ce projet, nous avons étudié l'algorithme d'espérance–maximisation (EM) dans le cadre des modèles de mélange, à la fois d'un point de vue théorique, méthodologique et appliqué. L'objectif principal était de comprendre comment fonctionne l'algorithme, ses conditions de validité, ainsi que ses limites pratiques lorsqu'il est appliqué à des données réelles.

Dans un premier temps, nous avons montré l'importance de l'étude préalable des distributions des données à l'aide de tests de normalité. Les comparaisons entre les tests de Shapiro–Wilk et de Lilliefors ont mis en évidence leurs comportements différents, notamment selon la taille des échantillons et la nature des déviations à la normalité. Cette étape exploratoire s'est révélée essentielle pour motiver l'utilisation de modèles de mélange, en particulier lorsque l'hypothèse de normalité globale est rejetée.

Nous avons ensuite formalisé le cadre probabiliste des modèles de mélange et détaillé le fonctionnement théorique de l'algorithme EM. Nous avons étudié plusieurs cas de figure allant des mélanges gaussiens aux mélanges plus complexes (Weibull, Gamma), afin d'illustrer la diversité des mises à jour paramétriques possibles et la nécessité, dans certains cas, de recourir à des optimisations numériques partielles.

Ensuite, nous avons mis en évidence l'impact négatif d'une mauvaise spécification du modèle de mélange, qui peut conduire à une surestimation du nombre de composantes et à un ajustement global de moindre qualité, malgré une log-vraisemblance élevée. On a également analysé l'influence de la taille de l'échantillon, confirmant que l'augmentation de n améliore la précision des estimations paramétriques et la stabilité des résultats.

Enfin, l'application biostatistique aux temps de vie des puits de clathrine a illustré l'intérêt concret de l'algorithme EM pour l'analyse de phénomènes biologiques complexes. L'étude des données a montré que les modèles de mélange permettent de révéler des sous-populations d'événements aux dynamiques distinctes. De plus, l'introduction d'une composante exponentielle à paramètre fixé a permis d'améliorer la séparation entre événements avortés et événements productifs, tout en soulignant la sensibilité de l'EM aux hypothèses imposées.

En conclusion, l'algorithme d'espérance–maximisation constitue un outil puissant pour l'analyse de données hétérogènes. Le choix du modèle, du nombre de composantes, des méthodes d'initialisation et des critères de sélection est déterminant pour garantir des résultats interprétables et statistiquement pertinents. Ce travail met en évidence la nécessité d'associer l'EM à une analyse exploratoire rigoureuse et à une réflexion approfondie sur les hypothèses de modélisation.

Bibliographie

Tests de normalité

— D'Agostino, R. B., & Stephens, M. A. (Eds.). (1986). *Goodness-of-Fit Techniques*. Marcel Dekker. ISBN : 978-0824774875.

— Razali, N.M. and Wah, Y.B. (2011). Power Comparisons of Shapiro–Wilk, Kolmogorov–Smirnov, Lilliefors and Anderson–Darling Tests. *Journal of Statistical Modeling and Analytics*, Vol. 2, No. 1, pp. 21–33.

— Lilliefors, H.W. (1967). On the Kolmogorov–Smirnov Test for Normality with Mean and Variance Unknown. *Journal of the American Statistical Association*, Vol. 62, No. 318, pp. 399–402.

Modèles de mélange et algorithme EM, sélection de modèles

— Picard, F. (2007). *An Introduction to Mixture Models*. Research Report No. 7, Statistics for Systems Biology Group, Laboratoire Statistique et Génome (CNRS UMR 8071 – INRA 1152 – Univ. d'Evry), Jouy-en-Josas / Paris / Evry, March 2007.

— James, G., Witten, D., Hastie, T., and Tibshirani, R. (2013). *An Introduction to Statistical Learning : with Applications in R*. Springer Texts in Statistics. Springer, New York. ISBN 978-1-4614-7137-0.

Contexte expérimental : endocytose

— Lagache, T., Nardi, G., Bertot, L., Grassart, A., Sauvonnet, N., and Olivo-Marin, J.-C. (2017). Combining Global Tracking with Statistical Classification to Analyze Endocytosis Dynamics Using TIRF Microscopy. *Proceedings of the IEEE International Symposium on Biomedical Imaging (ISBI)*. IEEE, pp. 1–5. DOI : 10.1109/ISBI.2017.7950706.